

Camera Installation Decision for Vending Machines

Executive Summary

- 歷史資料共 3,000 台販賣機，Broken rate 約為 38.5%，屬於偏高風險場景，在目前成本結構下低門檻保護策略有經濟合理性。
- 兩個模型的整體辨識力都有限，Random Forest 的 ROC AUC 較高 (0.547 vs 0.512)，但 Logistic Regression 在 threshold = 0.2 的測試集 realized cost 較低，因此最終商業決策採用 Logistic Regression。
- 在最佳模型下，1,000 個 candidate locations 中共有 1,000 台建議安裝 camera。
- Model-based strategy 的總預期成本為 2,000,000，低於 *outdoor – onlyhumanrule* 的 3,612,223。
- Camera effectiveness 至少要達到約 0.4 之後，模型才開始建議安裝任何 camera；之後效果愈好，安裝門檻愈低。
- 距離便利商店、社團活動暴露程度與建築類型是最值得優先管理的訊號，單純 indoor/outdoor 規則不夠精準。
- 在本案成本比下，若預算允許，全面保護或大規模保護策略可能優於只保護 outdoor 的經驗法則。

1. Data Overview

- 歷史訓練資料來源為 given/sales-data.csv，先依 location_id 聚合成 3,000 筆 location-level observations，再與 given/broken.csv 合併 target。
- 預測部署對象為 given/candidate-location.csv 的 1,000 個 location，先依 location 聚合後再套用最佳模型。
- 標準欄位 mapping 如下：

source_dataset	canonical_name	original_column
broken.csv	location_id	location_id
broken.csv	broken	broken
sales-data.csv	date	date
sales-data.csv	location_id	location_id
sales-data.csv	building_type	building_type
sales-data.csv	distance_to_store	distance_to_store
sales-data.csv	temperature	temperature
sales-data.csv	humidity	humidity
sales-data.csv	weekend	weekend
sales-data.csv	club_activity_day	club_activity_day
sales-data.csv	indoor	indoor
sales-data.csv	sales	sales
candidate-location.csv	date	date
candidate-location.csv	location_id	location_id
candidate-location.csv	building_type	building_type
candidate-location.csv	distance_to_store	distance_to_store
candidate-location.csv	temperature	temperature
candidate-location.csv	humidity	humidity
candidate-location.csv	weekend	weekend
candidate-location.csv	club_activity_day	club_activity_day
candidate-location.csv	indoor	indoor

- Broken rate: 38.5%

- 缺失值：三份原始檔案都沒有明顯缺失值，但 candidate data 有 indoor 隨日期變動的資料品質問題，因此本分析採用每個 location 的 mode 作為穩健值。
- 重要欄位定義： weekend 與 club_activity_day 於 location-level 以年度中該事件出現比例表示。

2. Question 1: Descriptive Analysis

2.1 Summary Statistics by Broken Status

metric	value
總樣本數	3,000.0000
Broken = 0 筆數	1,845.0000
Broken = 0 比例	0.6150
Broken = 1 筆數	1,155.0000
Broken = 1 比例	0.3850

Binary features summary:

broken	Indoor mean	Weekend mean	Club Activity Day mean
0.0000	0.5388	0.2842	0.1998
1.0000	0.5680	0.2842	0.1997

Distance summary:

broken	count	mean	std	median	min	max	q1	q3
0.0000	1,845.0000	248.0580	145.1517	248.0000	0.0000	499.0000	123.0000	378.0000
1.0000	1,155.0000	247.5385	141.2315	247.0000	0.0000	499.0000	124.0000	369.0000


Building type distribution and broken rate:

building_type	broken_0_count	broken_1_count	share_broken_0	share_broken_1	machine_count	broken_rate
classroom	444.0000	307.0000	0.2407	0.2658	751.0000	0.4088
dorm	476.0000	279.0000	0.2580	0.2416	755.0000	0.3695
gym	446.0000	284.0000	0.2417	0.2459	730.0000	0.3890
office	479.0000	285.0000	0.2596	0.2468	764.0000	0.3730


解讀：

- 單看 unconditional summary statistics，Broken = 1 與 Broken = 0 的平均差異其實不大，說明這份資料的可分性偏弱，不能只靠單一變數做判斷。
- 相對較有訊號的是 building type 與 indoor 的 broken rate 差異，但幅度仍屬溫和； weekend 幾乎沒有辨識力。
- 商業上這代表 vandalism risk 比較像是多個場域條件共同作用，而不是由單一規則直接驅動，因此需要模型把多個弱訊號合併起來看。


2.2 Visualizations




整體 broken rate 不低，意味著如果 camera 能有效降低損失，決策門檻會相對容易被跨過。




不同 building type 的 broken rate 有可觀差異，代表場域屬性本身反映不同的人流、管理密度與暴露風險。



Indoor 與 outdoor 有一些差異，但幅度不大，因此只用 outdoor-only rule 做部署仍然過於粗糙。



Weekend 幾乎沒有區辨力，顯示單純依賴週末時段做長期設備部署不夠有效。




Club activity 的單變數差異不算大，但在與其他特徵一起使用時仍可能提供額外排序資訊，適合作為巡檢與監控加強的輔助訊號。




Distance 的單變數分布差異有限，但在樹模型中仍是最重要特徵，表示它比較像是和其他條件一起作用的交互型訊號。

Broken Rate: Building Type x Indoor



Building type 與 indoor 之間存在交互差異，不同建築物在室內外場景下的風險並不一致。



Indoor 與社團活動日的交互圖顯示，活動暴露可能會放大原有風險，值得列入營運排程管理。

3. Question 2: Classification Modeling

3.1 Logistic Regression

Baseline category: classroom


Coefficient and odds ratio table:

feature	coefficient	odds_ratio
building_type_dorm	-0.2282	0.7960
indoor	0.1728	1.1886
building_type_gym	0.0150	1.0151
weekend	-0.0098	0.9902
building_type_office	-0.0058	0.9942
distance_to_store	0.0035	1.0035
club_activity_day	-0.0016	0.9984

Performance table:

model	threshold	roc_auc	brier_score	accuracy	precision	recall	f1_score	installed_count	expected_cost	real
Logistic Regression	0.2000	0.5124	0.2497	0.3850	0.3850	1.0000	0.5560	600.0000	1,200,000.0000	1,200,000.0000

model	threshold	roc_auc	brier_score	accuracy	precision	recall	f1_score	installed_count	expected_cost	real
Logistic Regression	0.5000	0.5124	0.2497	0.5733	0.4332	0.3506	0.3876	187.0000	2,378,584.5117	1,874



Logistic Regression 在 threshold = 0.2 時 recall 很高，符合「寧可多裝也不要錯過高損失點位」的商業邏輯，但代價是 precision 偏低、決策容易趨近全面安裝。

3.2 Random Forest

Feature importance table:


feature	importance
distance_to_store	0.5807
club_activity_day	0.3702
indoor	0.0157
building_type_gym	0.0126
building_type_dorm	0.0123
building_type_office	0.0085
weekend	0.0000


Permutation importance table:

feature	importance_mean	importance_std
club_activity_day	0.0387	0.0175
building_type	0.0292	0.0193
indoor	0.0260	0.0157
distance_to_store	0.0141	0.0147
weekend	0.0000	0.0000

Performance table:

model	threshold	roc_auc	brier_score	accuracy	precision	recall	f1_score	installed_count	expected_cost	realize
Random Forest	0.2000	0.5467	0.2491	0.3850	0.3846	0.9957	0.5549	598.0000	1,199,351.8524	1,206,000
Random Forest	0.5000	0.5467	0.2491	0.5400	0.4111	0.4502	0.4298	253.0000	1,888,983.2142	1,776,000





Random Forest 的 AUC 較高，說明它的排序能力略好，但 calibration 與 threshold 0.2 下的 realized cost 不如 Logistic Regression。

3.3 Model Comparison

model	threshold	roc_auc	brier_score	accuracy	precision	recall	f1_score	expected_cost	realized_cost
Logistic Regression	0.2000	0.5124	0.2497	0.3850	0.3850	1.0000	0.5560	1,200,000.0000	1,200,000.0000
Random Forest	0.2000	0.5467	0.2491	0.3850	0.3846	0.9957	0.5549	1,199,351.8524	1,206,000.0000
Random Forest	0.5000	0.5467	0.2491	0.5400	0.4111	0.4502	0.4298	1,888,983.2142	1,776,000.0000
Logistic Regression	0.5000	0.5124	0.2497	0.5733	0.4332	0.3506	0.3876	2,378,584.5117	1,874,000.0000

建議採用 Logistic Regression 作為最後商業決策模型，原因是本案的成本函數偏向保守防禦，threshold = 0.2 下的實際成本表現比單純 AUC 更重要。雖然 Random Forest 在 AUC 上略勝，但 improvement 不大，且並沒有轉化成更低的測試集 realized cost。

3.4 Most Influential Features

- 距離便利商店越遠的點位在 Random Forest 中最重要，代表外部監督或人流可見度可能是核心風險因子。
- Logistic Regression 的係數顯示 dorm 與 baseline classroom 相比風險略低，而 indoor 的係數接近零，表示單靠室內外不足以完全解釋破壞。
- Club activity day 的平均值在高風險群較高，支持活動日人潮或停留行為與破壞風險關聯。
- Weekend 在 location-level 幾乎沒有區辨力，因為每個地點面對類似的週末日曆結構，商業上不宜過度解讀。

4. Question 3: Business Recommendation

4.1 Model-based Camera Installation Decision

- 決策邏輯：若 camera effectiveness = 1，當 $p_i > 0.2$ 時應安裝 camera。
- 採用模型：Logistic Regression
- 建議安裝台數：1,000
- 完整清單已輸出為 outputs/tables/camera_recommendations.csv

Strategy comparison:


strategy	cameras_installed	installation_cost	expected_vandalism_loss	total_expected_cost	cost_gap_vs_model
Model-based	1,000.0000	2,000,000.0000	0.0000	2,000,000.0000	0.0000
Outdoor-only human rule	497.0000	994,000.0000	2,618,222.8060	3,612,222.8060	1,612,222.8060

4.2 Characteristics of High-risk Machines

metric	high_risk	overall
Machine count	1,000.0000	1,000.0000
Outdoor share	0.4970	0.4970
Average distance to store	252.9350	252.9350
Weekend share	0.2849	0.2849
Club activity day share	0.2002	0.2002
Average predicted probability	0.4984	0.4984

Risk segmentation:

risk_segment	machine_count	avg_probability	avg_distance
Low	0.0000		
Medium	0.0000		
High	1,000.0000	0.4984	252.9350




本案選定模型在 threshold = 0.2 下建議對全部 1,000 個 candidate locations 安裝 camera，因此「高風險子集合」實際上等於整個 candidate pool。這代表在目前成本假設下，模型認為整體風險水位都高於經濟門檻；若管理上無法全面部署，就應改用 budget scenario 與機率排序做優先配置。

4.3 Model-based Strategy vs Human Rule


- Outdoor-only rule 只根據 indoor = 0 裝設，忽略了部分 indoor 但同樣高風險的 location。
- Model-based strategy 的總預期成本較低，差額為 \$1,612,223。
- 因此 model 提供了比 human rule 更好的 cost-benefit outcome。

4.4 Sensitivity Analysis


effectiveness	threshold	cameras_installed	installation_cost	remaining_expected_vandalism_loss	total_expected_cost
0.0000		0.0000	0.0000	4,984,121.0145	4,984,121.0145
0.1000	2.0000	0.0000	0.0000	4,984,121.0145	4,984,121.0145
0.2000	1.0000	0.0000	0.0000	4,984,121.0145	4,984,121.0145
0.3000	0.6667	0.0000	0.0000	4,984,121.0145	4,984,121.0145
0.4000	0.5000	387.0000	774,000.0000	4,157,825.1957	4,931,825.1957
0.5000	0.4000	1,000.0000	2,000,000.0000	2,492,060.5072	4,492,060.5072
0.6000	0.3333	1,000.0000	2,000,000.0000	1,993,648.4058	3,993,648.4058
0.7000	0.2857	1,000.0000	2,000,000.0000	1,495,236.3043	3,495,236.3043
0.8000	0.2500	1,000.0000	2,000,000.0000	996,824.2029	2,996,824.2029
0.9000	0.2222	1,000.0000	2,000,000.0000	498,412.1014	2,498,412.1014
1.0000	0.2000	1,000.0000	2,000,000.0000	0.0000	2,000,000.0000



Camera Effectiveness vs Cameras Installed



Camera Effectiveness vs Installation Threshold



解讀：

- 當 effectiveness 很低時，threshold 會高於 1，因此沒有任何 machine 值得安裝 camera。
- effectiveness 提升時， $\text{threshold} = 0.2 / e$ 會下降，表示只要 camera 更有效，就算機器只有中度風險也可能值得投資。
- 一旦 threshold 進入模型機率分布的密集區間，建議安裝數量會快速增加，形成明顯的轉折點。

5. Additional Insights and Strategic Recommendations

Budget scenarios:

budget	selected_machine_count	installation_cost	total_expected_cost	avg_probability_selected	min_probability_selected
50.0000	50.0000	100,000.0000	4,815,231.6979	0.5378	0.5372
100.0000	100.0000	200,000.0000	4,646,886.3117	0.5372	0.5359
200.0000	200.0000	400,000.0000	4,312,841.6043	0.5356	0.5330

- 若預算有限，應優先安裝在 predicted probability 與 expected benefit 最高的點位，而不是先從所有 outdoor 位置下手。
- 模型支持的建議：優先處理距離便利商店較遠、社團活動暴露較高、且屬於高 broken-rate building type 的位置。
- 合理但需要進一步驗證的建議：調整高風險販賣機位置、在社團活動日增加巡邏、補強照明與現場管理密度。
- 風險分群可以作為營運 SOP：Low risk 以例行巡檢為主，Medium risk 搭配重點巡檢或移機評估，High risk 優先考慮 camera 或實體監控升級。

6. Limitations and Next Steps

- 目前 target Broken 是過去一年結果，未必能完全代表下一年度行為模式。
- Weekend 與 Club Activity Day 來自日資料，但 target 是年度結果，因此存在時間尺度不一致問題。
- Candidate data 的 indoor 在部分 location 會隨日期切換，顯示原始資料品質可能有定義不一致，需要和資料提供方再確認。
- 模型整體 AUC 不高，代表現有變數只能解釋部分風險；若能加入人流量、照明、樓層、管理員、維修紀錄等變數，效果應可明顯提升。
- 若未來 camera 安裝後改變 vandalism 行為，模型需要重新校正，不能假設歷史資料永遠有效。